

Adult Census Income

1. Uvod

Ovaj projekat se bavi predviđanjem godišnjeg prihoda pojedinaca na osnovu njihovih demografskih i radnih karakteristika. Cilj je klasifikovati osobe u jednu od dve grupe: one čiji je godišnji prihod ≤ 50.000 USD i one čiji je prihod > 50.000 USD.

Zašto mašinsko učenje?

Problem predviđanja prihoda je, po svojoj prirodi, složen – postoji mnogo faktora koji utiču na prihod, a njihovi međusobni odnosi su često nelinearni i teško ih je opisati jednostavnim matematičkim formulama. Tradicionalni statistički pristupi (poput linearne regresije) često ne mogu da obuhvate sve ove kompleksnosti.

Opis podataka

Za potrebe ovog projekta korišćen je Adult Census Income dataset (skup podataka o prihodima iz američkog popisa stanovništva) iz UCI Machine Learning Repository. Dataset sadrži podatke prikupljene tokom američkog popisa stanovništva 1994. godine.

Karakteristike dataset-a:

Broj instanci: ~48.000 (train + test)

Broj atributa: 14 (nakon preprocesiranja ~81)

Tip problema: Binarna klasifikacija

Ciljna varijabla: income (dve klase: $\leq 50K$ i $> 50K$)

Spisak atributa:

<i>Atribut</i>	<i>Tip</i>	<i>Opis</i>
age	Numerički	Godine starosti
workclass	Kategorički	Klasa poslodavca
fnlwgt	Numerički	Težinski faktor (uklonjen)
education	Kategorički	Stepen obrazovanja (uklonjen)
education_num	Numerički	Numerička vrednost obrazovanja
marital_status	Kategorički	Bračno stanje
occupation	Kategorički	Zanimanje
relationship	Kategorički	Porodični odnos
race	Kategorički	Rasa
sex	Kategorički	Pol
capital_gain	Numerički	Kapitalni dobitak
capital_loss	Numerički	Kapitalni gubitak
hours_per_week	Numerički	Radni sati nedeljno
native_country	Kategorički	Zemlja porekla
income	Kategorički	Ciljna varijabla ($\leq 50K$ / $> 50K$)

Izazovi u radu sa podacima

Prilikom rada sa Adult dataset-om, identifikovano je nekoliko izazova:

1. Nedostajuće vrednosti – neki atributi sadrže ? umesto vrednosti
2. Nebalansirane klase – samo 24.2% instanci pripada klasi >50K
3. Kategorički atributi – većina atributa je kategorička
4. Duplikati – postojanje dupliciranih redova
5. Outlier-i – ekstremne vrednosti u određenim atributima

2. PREPROCESIRANJE PODATAKA

Pre izbora i treniranja modela, podaci su prošli kroz sledeće korake:


1. Provera nedostajućih vrednosti – zamenjene su sa NaN
2. Popunjavanje nedostajućih vrednosti:
 - Numeričke kolone (capital_gain, capital_loss) → medijana
 - Kategoričke kolone (workclass, occupation, native_country) → mod (najčešća vrednost)
3. Uklanjanje irrelevantnih atributa:
 - fnlwgt – težinski faktor (ne utiče na prihod)
 - education – duplikat education_num
4. Brisanje duplikata – zadržava se prvi primerak
5. Enkodiranje:
 - LabelEncoder za target (income)
 - One-hot encoding za kategoričke attribute (drop_first=True)
6. Podela podataka:
 - Train: 85% originalnog train skupa (24,094)
 - Validation: 15% originalnog train skupa (4,253)
 - Test: ceo adult_test.csv (14,985)
7. Skaliranje:
 - Korišćen je StandardScaler
 - Fit na train skupu, transform na validation i test skupu

Rezultati preprocesiranja:

<i>Skup</i>	<i>Pre čišćenja</i>	<i>Posle čišćenja</i>	<i>Obrisano duplikata</i>
<i>Train</i>	32,561	28,347	4,214 (12.94%)
<i>Test</i>	16,281	14,985	1,296 (7.96%)


3. EKSPLOLATIVNA ANALIZA (EDA)

Distribucija prihoda - Train skup




Zaključak: Dataset je nebalansiran – više je osoba sa nižim primanjima. Zato je korišćen F1-Score umesto Accuracy.


Prihod po polu



Zaključak: Veći procenat muškaraca ima prihod $> 50K$ u odnosu na žene. Pol je značajan faktor za predikciju.



Zaključak: Nema jakih korelacija između atributa (>0.7), što znači da nema problema sa multikolinearnošću.



Zaključak:

- Ljudi sa >50K su u proseku stariji (medijana ~45)
- Ljudi sa >50K rade više sati (medijana ~45)

```

=====
PROVERA ANOMALIJA - Train skup (posle brisanja duplikata)
=====

👤 Age:
Min: 17
Max: 90
Mean: 39.23
Std: 13.75
⚠️ Ima 294 osoba mlađjih od 18 godina

👤 Hours per week:
Min: 1
Max: 99
Mean: 40.60
Std: 12.86
⚠️ Ima 206 osoba sa preko 80 radnih sati

```

```

=====
PROVERA ANOMALIJA - Test skup (posle brisanja duplikata)
=====

👤 Age:
Min: 17.0
Max: 90.0
Mean: 39.22
Std: 13.94
⚠️ Ima 178 osoba mlađjih od 18 godina

👤 Hours per week:
Min: 1.0
Max: 99.0
Mean: 40.48
Std: 12.80
⚠️ Ima 110 osoba sa preko 80 radnih sati

```

Zaključak: Ove vrednosti su validne zato što je u SAD-u legalno biti zaposlen maloletan i neki ljudi rade više poslova što povećava ukupan broj radnih sati.

Takođe, *capital_gain* i *capital_loss* nisu izbačeni niti prevedeni u logičke vrednosti, zato što su to potpuno relevantni podaci za određivanje primanja osobe.

4. MODELI I TRENIRANJE

Testirani modeli:

<i>Model</i>	<i>Metod optimizacije</i>
Logistic Regression Baseline	(LogisticRegressionCV)
SVM	GridSearchCV
Random Forest	GridSearchCV
Gradient Boosting	Optimalni parametri
XGBoost	GridSearchCV
XGBoost (Top 5)	Redukovani model

Hiperparametri najboljeg modela (Gradient Boosting):



```
n_estimators=150,
learning_rate=0.08,
max_depth=5,
subsample=0.80,
random_state=42
```



Rezultati na validacionom skupu:



```
=====
VALIDACIONI REZULTATI (F1 skor)
=====
Gradient Boosting: 0.7359
XGBoost: 0.7332
Random Forest: 0.7223
XGBoost (Top 5): 0.7206
SVM: 0.7035
Logistic Regression: 0.6674
=====
```

Na osnovu validacionih rezultata, Gradient Boosting se izdvaja kao najbolji model sa F1-Score-om od 0.7359, što je poboljšanje od ~6.9% u odnosu na baseline model (Logistic Regression, F1=0.6674). XGBoost je veoma blizu sa F1=0.7332, dok Random Forest (0.7223) i SVM (0.7035) zaostaju. Svi modeli su zatim evaluirani na test skupu radi konačnog poređenja.

5. REZULTATI







Finalni izveštaj:

Korišćene metrike:

- Accuracy - procenat tačno klasifikovanih instanci
- Precision - tačnost pozitivnih predikcija
- Recall - procenat otkrivenih pozitivnih instanci
- F1-Score - harmonična sredina preciznosti i odziva
- ROC-AUC - sposobnost razlikovanja klasa

GradientBoosting(Optimized)(threshold=0.42)

- 0.872605939272606,0.7294754846066135,0.7271952259164536,0.7283335705137327,0.9287497359900234
- Sekvencijalno uči na greškama prethodnih stabala, što mu omogućava da uhvati složene obrasce u podacima. Ne zahteva skaliranje i robustan je na outlier-e, što ga čini idealnim za ovaj nebalansirani dataset.

XGBoost(Optimized)

- 0.8369703036369703,0.6088187702265372,0.8553566354077863,0.7113316790736146,0.9284775721263361
- Ima istu sekvencijalnu logiku kao Gradient Boosting, ali je agresivnija regularizacija (L1/L2) „ugušila“ neke signale u podacima. Zato je neznatno lošiji, iako je i dalje veoma dobar.

RandomForest(Optimized)

- 0.8256256256256256,0.5899166335847559,0.8445581131003126,0.6946359705504266,0.918470435368499
- Trenira stabla paralelno, ali ne ispravlja greške prethodnih stabala, pa ne može da nauči kompleksne obrasce kao boosting metode. Zato zaostaje za Gradient Boosting-om i XGBoost-om.

XGBoost(Reduced-Top5)

- 0.8211544878211545,0.5805646245438832,0.859050866723501,0.6928718771487509,0.9187904072814558
- Koristi samo 5 najvažnijih atributa, što ga čini izuzetno jednostavnim i interpretabilnim. Iako postiže 95% performansi punog modela, gubitak informacija iz ostalih 76 atributa ga svrstava na četvrto mesto.


SVM(SupportVectorMachine)

- 0.8115448782115449,0.5647716682199441,0.8610400682011935,0.6821251688428636,0.9067798307233212
- Osetljiv je na outlier-e i zahteva skaliranje, što mu otežava rad sa podacima koji sadrže ekstremne vrednosti (capital_gain, capital_loss). Ima najveći Recall (86.1%), ali niska preciznost ga spušta na peto mesto.

LogisticRegression(Baseline)

- 0.8544544544544454,0.7326147426981919,0.5987496447854505,0.6589523064894449,0.9053850451365979
- Kao linearni model, ne može da uhvati nelinearne odnose između atributa i prihoda, što je ključni nedostatak za ovaj problem. Služi kao baseline za poređenje – pokazuje koliko su složeniji modeli zapravo bolji.

6. NAJVAŽNIJI ATRIBUTI



Zaključak: Bračno stanje je najvažniji prediktor prihoda. Oženjeni/udati ljudi češće imaju prihod >50K.

Redukovani modeli:

Model	Broj atributa	F1-Score	Procenat performansi
Gradient Boosting (full)	81	0.7283	100%

XGBoost (Top 5)

5

0.6929

95.1%

Zaključak: Samo 5 atributa daje 95% performansi punog modela, što ga čini odličnim izborom kada je interpretabilnost važna.

7. DEPLOYMENT

Svi modeli su eksportovani u models/ folder:

models/

— gradient_boosting.pkl	← Najbolji model
— best_threshold.pkl	← threshold=0.42
— logistic_regression.pkl	
— svm.pkl	
— random_forest.pkl	
— xgboost.pkl	
— xgboost_reduced.pkl	
— top_5_features.pkl	
— top_10_features.pkl	

Streamlit UI omogućava:

- Unos svih atributa kroz forme
- Predikciju prihoda sa verovatnoćom
- Vizuelni prikaz rezultata

Adult Census Income Predictor

Predviđanje da li osoba zarađuje više od 50.000\$ godišnje

Model užitak: Gradient Boosting (threshold=0.42)

Osnovne informacije

Godine starosti

28

Pol

Male

Nivo obrazovanja (0-16)

9

Bračno stanje

Divorced

Porodični odnos

Husband

Rasa

Black

Radne informacije

Klasa posla

Private

Zanimanje

Adm-clerical

Radni sati nedeljno

41

Kapitalni dobitak (capital gain)

0

Kapitalni gubitak (capital loss)

0

Zemlja porekla

United States

PREDVIĐAJ PRIHOD

PREDIKCIJA: ≤50K\$

Verovatnoća: 98.4%

Activate Windows

8. ZAKLJUČAK

U ovom projektu uspešno je kreiran model za predviđanje prihoda na Adult Census Income dataset-u. Nakon preprocesiranja podataka, eksplorativne analize, treniranja i evaluacije više modela, Gradient Boosting se pokazao kao najbolji sa F1-Score-om od 0.7283 i ROC-AUC od 0.9287.

Primeri nekih drugih modela:

- KNN (K-Nearest Neighbors) - jednostavan je, ali je spor za velike dataset-ove i loš je u visokim dimenzijama. Sa 81 atributom, verovatno ne bi bio dobar izbor za ovaj problem
- Decision Tree (Stablo odlučivanja) - pojedinačno stablo odlučivanja je često nestabilno i overfit-uje podatke. Ansambl metode (Random Forest, Boosting) su skoro uvek bolje

Ključni zaključci:

1. Najbolji model: Gradient Boosting (F1=0.7283, ROC-AUC=0.9287)
2. Najvažniji atribut: Bračno stanje (marital_status_Married-civ-spouse)
3. Redukovani model: Samo 5 atributa daje 95% performansi punog modela
4. Izazov: Dataset je nebalansiran (75.8% $\leq$ 50K), pa je F1-Score korišćen umesto Accuracy

Deployment: Model je uspešno deploy-ovan kroz Streamlit UI

Praktična primena: Ovaj model može se koristiti u bankarskom sektoru za procenu kreditnog rizika, u marketingu za ciljanje potrošača, ili u analizi tržišta rada za identifikaciju faktora koji utiču na ekonomski status.